

Simulador de Combate

Informe del pipeline de ciencia de datos

Fecha de generacion: 2026-06-15 20:30

Este informe documenta el proceso completo: ingesta de datos por web scraping, normalizacion, base de datos NoSQL, simulacion de combates, modelos de machine learning y procesamiento distribuido con Apache Spark.

1. Datos del pipeline

Personajes en la base: 6

Fuentes de datos: paises, pokemon, superheroes

Combates simulados: 3000

Los personajes provienen de distintas fuentes web y fueron normalizados a una escala comun (1-255) con Min-Max para que puedan enfrentarse de forma justa.

2. Machine Learning (scikit-learn)

3.1.1 Clasificación (predecir el ganador):

Precision del modelo: 99.7%

3.1.2 Regresión (predecir turnos del combate):

Error medio: 0.19 turnos

R²: 0.86

3.2.1 Análisis de grupos (KMeans):

	hp	ataque	defensa	velocidad
nombre_grupo				
Atacante	237.5	242.5	175.0	45.0
Resistente	200.0	150.0	40.0	30.0
Veloz	103.3	140.0	106.7	152.3

3. Procesamiento distribuido (Apache Spark)

3.3.1 y 3.3.2 RDD y transformaciones:

Se cargaron los combates como RDD y se contaron las victorias por personaje con map/filter/reduceByKey.

3.3.3 SparkSQL y SparkMLlib:

Promedio de turnos (SQL): 1.7323333333333333

Precision del modelo MLlib: 99.3%

Top ganadores (SparkSQL):

China: 499

Hulk: 411

Charizard: 291


Batman: 195

Mexico: 101

Victorias por personaje



Grupos de personajes (KMeans)



Matriz de confusion (clasificacion)

